

Поиск частых наборов объектов алгоритмом Apriori

Лабораторная работа по курсу «Анализ больших данных»

Выполнил: _____ Сюй Канлэ _____ Группа: __ЕТ-461__

Дата: 14.09.2026

1. Постановка задачи

Требуется разработать программу, которая выполняет поиск частых наборов объектов (frequent itemsets) в заданном наборе данных с помощью алгоритма Apriori. Список результирующих наборов должен содержать как сами наборы, так и значение поддержки (support) для каждого набора. Параметрами программы являются: набор данных, порог поддержки и способ упорядочивания результирующего списка наборов — по убыванию значения поддержки или лексикографически.

Необходимо провести эксперименты на наборе данных baskets.csv (сведения о покупках в супермаркете), варьируя пороговое значение поддержки: 1%, 3%, 5%, 10%, 15%. Требуется выполнить визуализацию результатов экспериментов в виде двух диаграмм: (1) сравнение быстродействия на фиксированном наборе данных при изменяемом пороге поддержки; (2) количество частых наборов объектов различной длины при изменяемом пороге поддержки.

Дополнительное требование: для найденных частых наборов („цепочек“) построить ассоциативные правила и проверить их с помощью параметров достоверности (confidence) и повышения/лифта (lift), а также вычислить поддержку каждого правила. Отчёт о выполнении задания подготовить в формате PDF со следующими разделами: формулировка задания; гиперссылка на каталог репозитория с исходными текстами, наборами данных и сопутствующими материалами; рисунки с результатами визуализации; пояснения, раскрывающие смысл полученных результатов.

2. Каталог репозитория

Все исходные тексты, набор данных и результаты экспериментов размещены в каталоге репозитория (локальная файловая система):

C:\Users\34129\Doubao\chats\2026-09-14\new-chat\apriori-project

Структура каталога:

apriori-project/	
├── data/baskets.csv	— исходный набор данных (7500 транзакций)
├── src/apriori.py	— основная программа (алгоритм Apriori + правила)
├── src/experiments.py	— скрипт экспериментов (пороги 1%–15%, замер времени)
├── src/rules_exp.py	— скрипт генерации и проверки ассоциативных правил
├── src/make_tree.py	— построение дерева частых наборов (рис. 4)
├── results/	— результаты в формате CSV (summary, lengths, rules)
├── figures/	— рисунки fig1..fig4 (быстродействие, длины, дерево)
└── report/	— настоящий отчёт (PDF)

3. Исходные данные

Набор данных baskets.csv содержит сведения о покупках в супермаркете. Каждая строка файла соответствует одной корзине (транзакции); товары в строке разделены запятыми. Кодировка файла — Windows-1251 (cp1251). После загрузки и очистки данных получены следующие характеристики: 7500 транзакций, 115 различных товаров, средний размер корзины 3,91 товара, максимальный размер корзины 19 товаров. Пустые транзакции отсутствуют; дубликаты товаров внутри одной корзины схлопываются (корзина рассматривается как множество).

4. Метод

4.1. Алгоритм Apriori

Apriori — классический алгоритм поиска частых наборов. Он опирается на свойство антимонотонности: любое подмножество частого набора также является частым. На каждом шаге k алгоритм строит кандидатов длины k из частых наборов длины $k-1$ (шаг соединения), отсекает заведомо нечастых кандидатов (шаг отсеечения), затем сканирует базу транзакций и оставляет кандидатов с поддержкой не ниже порога. Процесс продолжается, пока порождаются новые частые наборы.

Поддержка набора X определяется как доля транзакций, содержащих X : $\text{support}(X) = (\text{число транзакций, содержащих } X) / |D|$. Порог поддержки задаётся в процентах от числа транзакций. Результирующий список может упорядочиваться двумя способами: по убыванию поддержки (--sort support) или лексикографически (--sort lex).

4.2. Ассоциативные правила

Из частых наборов порождаются ассоциативные правила вида $A \rightarrow B$, где A и B — непересекающиеся непустые подмножества частого набора. Для каждого правила вычисляются:

- поддержка: $\text{sup}(A \rightarrow B) = \text{support}(A \text{ и } B \text{ вместе})$;
- достоверность: $\text{conf}(A \rightarrow B) = \text{support}(A \text{ и } B) / \text{support}(A)$;
- лифт: $\text{lift}(A \rightarrow B) = \text{conf}(A \rightarrow B) / \text{support}(B)$.

Лифт показывает, во сколько раз совместная встречаемость A и B выше той, которую следовало бы ожидать при независимости A и B . Если $\text{lift} > 1$ — связь положительная (товары тяготеют друг к другу), $\text{lift} = 1$ — независимость, $\text{lift} < 1$ — отрицательная связь.

5. Результаты экспериментов

Программа запускалась на наборе baskets.csv при порогах поддержки 1%, 3%, 5%, 10% и 15%. Для каждого порога замерялось время выполнения алгоритма Apriori (без учёта загрузки данных) и подсчитывалось число частых наборов различной длины. Сводные результаты приведены в таблице 1.

Порог	Мин. подд. (транз)	Время, с	Всего наборов	Длина 1	Длина 2	Длина 3	Макс. длина
1%	75	1,993	263	74	172	17	3
3%	225	0,439	55	36	19	0	2
5%	375	0,210	28	25	3	0	2
10%	750	0,024	7	7	0	0	1
15%	1125	0,016	5	5	0	0	1

Таблица 1. Результаты экспериментов при различных порогах поддержки.




Рисунок 1. Сравнение быстродействия алгоритма Apriori на фиксированном наборе данных при изменяемом пороге поддержки.




Рисунок 2. Количество частых наборов различной длины на фиксированном наборе данных при изменяемом пороге поддержки.




Рисунок 3. Общее число частых наборов как функция порога поддержки (вспомогательная диаграмма).

6. Дерево наиболее вероятных (частых) наборов

Чтобы наглядно представить, как из отдельных товаров вырастают самые вероятные сочетания покупок, частые наборы выстроены в виде префиксного дерева (по аналогии с разбором на занятии). Корень дерева — все 7500 транзакций; от него отходят самые частые товары первого уровня (минеральная вода — 23,8%, макароны — 18,8%, яйца — 18,0%, картофель-фри — 17,1%, шоколад — 16,4%, зелёный чай — 13,2%). Далее от каждого товара вниз идут частые пары, а от пар — частые тройки. На каждом узле подписан размер поддержки в транзакциях и в процентах.

Дерево показывает «наиболее вероятные тренды» покупательского поведения: например, ветвь «минеральная вода → +макароны → +говяжий фарш» — это частый путь (23,8% → 6,1% → 1,7%), то есть сочетание «минеральная вода, макароны и говяжий фарш» встречается в 1,7% корзин. По мере движения вниз по дереву поддержка узлов закономерно уменьшается (свойство антимонотонности): любой узел уже, а значит реже встречается, чем его родитель. Самые «густые» ветви (с наибольшей поддержкой на каждом уровне) соответствуют наиболее вероятным товарным сочетаниям.




Рисунок 4. Дерево наиболее вероятных (частых) наборов при пороге поддержки 1%. На узлах указано количество

транзакций и относительная поддержка.

7. Ассоциативные правила и их проверка

Ассоциативные правила порождались из частых наборов, найденных при пороге поддержки 1% (при более высоких порогах количество двухэлементных частых наборов недостаточно для содержательных правил). Правила проверялись по параметрам достоверности ($\text{confidence} \geq 0,3$) и лифта. Всего получено 65 правил. В таблице 2 приведены 10 правил с наибольшим значением лифта.

Правило ($A \rightarrow B$)	Поддержка	Достоверность	Лифт
травы и перец $\rightarrow$ говяжий фарш	0,016	0,32	3,29
зам. овощи, мин. вода $\rightarrow$ молоко	0,011	0,31	2,39
суп $\rightarrow$ молоко	0,015	0,30	2,32
говяжий фарш, мин. вода $\rightarrow$ макароны	0,017	0,42	2,24
говяжий фарш $\rightarrow$ макароны	0,040	0,41	2,18
говяжий фарш, яйца $\rightarrow$ мин. вода	0,010	0,51	2,13
говяжий фарш, молоко $\rightarrow$ мин. вода	0,011	0,50	2,11
перец $\rightarrow$ макароны	0,010	0,39	2,08
мин. вода, оливк. масло $\rightarrow$ макароны	0,011	0,39	2,07
говяжий фарш, шоколад $\rightarrow$ мин. вода	0,011	0,47	1,99

Таблица 2. Топ-10 ассоциативных правил по лифту (порог поддержки 1%, $\text{min_conf} = 0,3$).

Дополнительно правила проверялись при пороге 3%: при $\text{min_conf} = 0,5$ правила отсутствуют (максимальная достоверность среди двухэлементных наборов ниже 0,5), а при $\text{min_conf} = 0,3$ получено 7 правил, например «говяжий фарш $\rightarrow$ макароны» (поддержка 0,040, достоверность 0,41, лифт 2,18) и «молоко $\rightarrow$ минеральная вода» (поддержка 0,048, достоверность 0,37, лифт 1,55).

8. Пояснения к полученным результатам

1. Быстродействие. Время выполнения алгоритма резко растёт при снижении порога поддержки: при 15% алгоритм завершается за 0,016 с, а при 1% — почти за 2 с (рост примерно в 125 раз). Причина в том, что при низком пороге через шаг соединения проходит значительно больше кандидатов (больше частых наборов выживает после отсека), а на каждом уровне k требуется полное сканирование базы из 7500 транзакций. При 1% алгоритм доходит до наборов длины 3, при 10–15% частых наборов длины 2 не существует вовсе, поэтому число сканирований и объём работы минимальны. Наблюдаемая зависимость соответствует известной экспоненциальной чувствительности Apriori к порогу поддержки.

2. Число наборов разной длины. При любом пороге больше всего частых наборов имеет длину 1: например, при 1% это 74 одиночных товара. Число наборов длины 2 и 3 быстро падает с ростом порога: при 5% остаются лишь 3 пары, при 10% — ни одной. Это следствие антимонотонности: чтобы пара была частой, частыми должны быть оба её элемента, а совместная покупка двух конкретных товаров встречается значительно реже, чем каждый из них по отдельности.

3. Общее число частых наборов. Сводная картина (рисунок 3) демонстрирует резкое сокращение результата: 263 набора при 1% против 5 наборов при 15%. Это иллюстрирует ключевой компромисс при выборе порога: низкий порог даёт более полное, но шумное и дорогое по времени решение; высокий порог — компактное, быстрое, но

только с самыми массовыми закономерностями.

4. Смысл правил. Самые сильные правила (по лифту) связывают «мясные» и «бакалейные» категории: покупка говяжьего фарша повышает вероятность покупки макарон в 2,18 раза относительно независимости, а специи (травы и перец) — покупку говяжьего фарша в 3,29 раза. Минеральная вода часто выступает консеквентом, так как она сама по себе очень популярна (поддержка 23,8%), и правила с ней имеют умеренный лифт. Лифт > 1 во всех 65 правилах означает, что обнаруженные связи не являются артефактом высокой популярности отдельных товаров, а отражают реальную совместную встречаемость в корзинах.

9. Выводы

В ходе работы разработана программа поиска частых наборов на основе алгоритма Apriori с поддержкой двух способов упорядочивания результата (по поддержке и лексикографически) и генерацией ассоциативных правил с расчётом поддержки, достоверности и лифта. Программа успешно обрабатывает файл baskets.csv (7500 транзакций). Эксперименты подтвердили сильную зависимость времени выполнения и объёма результата от порога поддержки; получены и проинтерпретированы диаграммы быстродействия и распределения частых наборов по длине. Проверка ассоциативных правил по достоверности и лифту позволила выделить содержательные закономерности покупательского поведения, например связь «говяжий фарш → макароны» (лифт 2,18). Результаты воспроизводимы: исходные тексты, данные и результаты сохранены в репозитории (раздел 2).